



## (12) 发明专利申请

(10) 申请公布号 CN 120336783 A

(43) 申请公布日 2025. 07. 18

(21) 申请号 202510400956.9

G06N 3/0499 (2023.01)

(22) 申请日 2025.04.01

G06N 3/084 (2023.01)

(71) 申请人 南京工程学院

地址 210000 江苏省南京市江宁科学园弘  
景大道1号

(72) 发明人 黄新 李爽 孟凯涛 袁家雯  
陈光霁 杨伟博 张晗睿

(74) 专利代理机构 南京苏高专利商标事务所  
(普通合伙) 32204

专利代理师 徐红梅

(51) Int.Cl.

G06F 18/21 (2023.01)

G06F 18/213 (2023.01)

G06F 18/214 (2023.01)

G06F 18/241 (2023.01)


权利要求书3页 说明书10页 附图6页

### (54) 发明名称

一种基于改进FNN的智能家居空气检测识别  
方法、系统、设备及存储介质

### (57) 摘要

本发明公开了一种基于改进FNN的智能家居空气检测识别方法、系统、设备及存储介质,方法包括:采集室内空气中污染物数据,以及室内气压和温度数据;提取数据特征,并制作数据集,并对观测值进行预处理,得到数据样本集;构建改进后的FNN模型,基于样本集对模型进行训练,得到训练好的改进后的FNN模型;基于训练好的改进后的FNN模型对测试数据进行分类识别,得到分类结果。本发明利用STM32硬件平台、阿里云物联网平台和改进FNN算法相结合的方式,开发了新型智能家居空气检测系统,为后续智能环境控制系统的搭建提供可靠的技术支撑。



1. 一种基于改进FNN的智能家居空气检测识别方法,其特征在于,包括以下步骤:  
采集室内空气中污染物数据,以及室内气压和温度数据;  
提取数据特征,并制作数据集,数据集中数据格式为:气体标签;浓度值;特征:观测值;  
并对观测值进行预处理;得到数据样本集;

构建改进后的FNN模型,基于样本集对模型进行训练,得到训练好的改进后的FNN模型;  
其中,模型改进包括:每层采用Leaky Rectified Linear Unit激活函数,加入批量归一化在每一层的输出上进行规范化,归一化后的输出进行线性变换,对梯度下降或爆炸进行优化;每层都设置Dropout层,用于随机丢弃部分神经元,防止过拟合;采用Adam优化器进行参数优化,并采用交叉熵损失函数对模型进行训练评估。

基于训练好的改进后的FNN模型对测试数据进行分类识别,得到分类结果。

2. 根据权利要求1所述的基于改进FNN的智能家居空气检测识别方法,其特征在于,数据集中,每个气体标签对应多个浓度值和多个特征,每个特征对应多个观测值,对观测值进行预处理包括:采用均值填充策略填充缺失数据,并对填充后的每个特征对应的多个观测值进行标准化,标准化后数据集为样本集。

3. 根据权利要求1所述的基于改进FNN的智能家居空气检测识别方法,其特征在于,改进后的FNN模型中,Leaky Rectified Linear Unit激活函数表达式为:

$$f(x) = \max(\alpha x, x)$$

其中, $f(x)$ 表示激活函数的输出, $x$ 表示激活函数的输入值, $\alpha x$ 表示激活函数的输出值;  
批量归一化公式为:

$$\hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

其中, $\hat{x}$ 表示标准化后的中间值, $x$ 表示, $\mu_B$ 是当前批次数据上所有输入的均值, $\sigma_B^2$ 是当前批次数据上所有输入的方差, $\epsilon$ 是一个极小的正数;

线性变换公式为:

$$y = \gamma \hat{x} + \beta$$

其中, $y$ 表示批量归一化后的最终输出值, $\gamma$ 和 $\beta$ 分别是学习到的可调缩放和平移参数。

4. 根据权利要求1所述的基于改进FNN的智能家居空气检测识别方法,其特征在于,改进后的FNN模型中,Dropout层操作为:

$$\tilde{y} = y \cdot r$$

其中, $\tilde{x}$ 表示Dropout层处理后的输出数据, $x$ 表示Dropout层输入数据, $r$ 是一个随机生成的二进制掩码。

5. 根据权利要求1所述的基于改进FNN的智能家居空气检测识别方法,其特征在于,Adam优化器的更新规则为:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

$$\theta_t = \theta_{t-1} - \frac{\alpha \hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

梯度代表函数在某个点的方向导数向量,它指向函数值增加最快的方向,并且其大小表示函数变化的剧烈程度。在此项目中,表示函数在每个维度上的变化率。其中, $m_t$ 是当前动量(模拟物理中的速度),在梯度更新时给梯度增加一个惯性,使得优化路径更加平滑,不会过度摆动,通过指数移动平均累积梯度, $m_{t-1}$ 是前一步的动量, $\beta_1$ 是一阶矩的指数衰减率, $g_t$ 是当前时间步 $t$ 的梯度,即损失函数对参数 $\theta_{t-1}$ 的梯度; $v_t$ 是当前平方梯度的指数移动平均, $v_{t-1}$ 是前一步的平方梯度的指数移动平均, $\beta_2$ 是二阶矩的指数衰减率, $\hat{m}_t$ 是偏差修正后的动量, $\hat{v}_t$ 是偏差修正后的平方梯度, $\beta_1^t$ 是表示 $\beta_1$ 在第 $t$ 步的幂次, $\beta_2^t$ 是表示 $\beta_2$ 在第 $t$ 步的幂次, $\theta_t$ 是更新后的模型参数, $\theta_{t-1}$ 是前一步的参数, $\alpha$ 是学习率, $\epsilon$ 为数值稳定性常数;

交叉熵损失函数为:

$$L = - \sum_{i=1}^c y_i \log(p_i)$$

其中, $L$ 是损失值, $C$ 是类别数, $y_i$ 是实际标签, $p_i$ 是模型预测的类别 $i$ 的概率, $\log(p_i)$ 表示对预测概率 $p_i$ 取自然对数。

6.一种基于改进FNN的智能家居空气检测识别系统,其特征在于,包括:

数据采集模块,用于采集室内空气中污染物数据,以及室内气压和温度数据;

数据处理模块,用于提取数据特征,并制作数据集,数据集中数据格式为:气体标签;浓度值;特征:观测值;并对观测值进行预处理;得到数据样本集;

模型构建及训练模块,用于构建改进后的FNN模型,基于样本集对模型进行训练,得到训练好的改进后的FNN模型;其中,模型改进包括:每层采用Leaky Rectified Linear Unit激活函数,加入批量归一化在每一层的输出上进行规范化,归一化后的输出进行线性变换,对梯度下降或爆炸进行优化;每层都设置Dropout层,用于随机丢弃部分神经元,防止过拟合;采用Adam优化器进行参数优化,并采用交叉熵损失函数对模型进行训练评估。

分类识别模块,用于基于训练好的改进后的FNN模型对测试数据进行分类识别,得到分类结果。

7.根据权利要求6所述的基于改进FNN的智能家居空气检测识别系统,其特征在于,数据采集模块,包括STM32微控制器、空气检测模块、BMP280气压计模块、通信模块和物联网平台,空气检测模块用于检测室内空气中污染物数据,BMP280气压计模块用于采集室内气压和温度数据,污染物数据、气压和温度数据通过通信模块传输至STM32微控制器,STM32微控制器对数据进行处理后通过通信模块上传至物联网平台,物联网平台用于数据的显示和存储,并实现分类识别结果的保存和显示。

8.根据权利要求6所述的基于改进FNN的智能家居空气检测识别系统,其特征在于,STM32微控制器将实时检测数据通过OLED屏幕显示;

空气检测模块包括TGS2600、TGS2602、TGS2610和TGS2620四种不同空气检测传感器,通过加热电路和信号处理电路,将气体浓度转换为可测量的电压信号,再通过ADC转换为数字信号供STM32处理;

通信模块为ESP8266-12F WIFI模块,内置微控制器和TCP/IP协议栈,能够实现无线数据传输。

9.一种电子设备,其特征在于,所述设备包括:

存储有可执行程序代码的存储器;

与所述存储器耦合的处理器;

所述处理器调用所述存储器中存储的所述可执行程序代码,执行权利要求1-5任一项所述的基于改进FNN的智能家居空气检测识别方法的步骤。

10.一种计算机可读存储介质,其特征在于,所述计算机可读存储介质存储有计算机指令,所述计算机指令被调用时,用于执行如权利要求1-5任一项所述的基于改进FNN的智能家居空气检测识别方法的步骤。

## 一种基于改进FNN的智能家居空气检测识别方法、系统、设备及存储介质

### 技术领域

[0001] 本发明属于智能家居技术领域,尤其涉及一种基于改进FNN的智能家居空气检测识别方法、系统、设备及存储介质。

### 背景技术

[0002] 随着物联网技术的蓬勃发展,智能家居系统日益普及,成为人们追求便捷、舒适、健康生活的重要助力。在智能家居的众多功能模块中,空气质量检测至关重要,它直接关系到居住者的身体健康和生活质量。

[0003] 传统的空气检测技术主要依赖简单的传感器,这些传感器在面对复杂多变的室内环境时,暴露出诸多问题。一方面,精度不足是较为突出的缺陷。室内空气中存在着多种成分,不仅有常见的有害气体如甲醛、苯、TVOC(总挥发性有机化合物)等,还有湿度、温度等环境因素的干扰。普通传感器对这些气体的检测精度有限,容易受到其他气体交叉干扰,导致检测结果与实际浓度偏差较大。例如,在新装修的房屋中,多种挥发性有机化合物混合存在,传统传感器难以准确分辨多种气体中的某种气体是否存在,难以采取有效的应对措施。

[0004] 另一方面,数据可视化差也是一大难题。当室内空气质量发生变化时,如有人在室内吸烟,或者新家具释放有害气体,传统空气检测系统不能及时向其他的智能家居传递信息,使智能家居系统快速做出反应。这就导致用户可能在不知不觉中长时间暴露在污染的空气中,健康受到潜在威胁。而且,由于响应滞后,智能环境控制系统也无法及时启动相应的空气净化设备,影响了智能家居系统的整体实用性和智能性。

[0005] 与传统的空气检测需求不同,精度和数据可视化被广泛用作量化智能家居空气检测系统性能的关键指标。为了实现可靠的空气检测,已有相关学者(朱菊香等.基于STM32室内空气质量检测系统的设计与实现)致力于基于传感器的数据采集和处理技术,其中涉及数据预处理和特征提取。该方案均围绕最大限度降低环境干扰和传感器噪声引起的误差这一原则展开设计。尽管在理论上取得了进展,但由于随机环境变化,仅依靠传感器技术可能无法保证检测性能。

### 发明内容

[0006] 发明目的:本发明的目的是提供一种基于改进FNN的智能家居空气检测识别方法,能够有效提高检测精度和增强数据可视化效果,为后续智能环境控制系统的搭建提供可靠的技术支撑。

[0007] 技术方案:本发明所述一种基于改进FNN的智能家居空气检测识别方法,包括以下步骤:

[0008] 采集室内空气中污染物数据,以及室内气压和温度数据;

[0009] 提取数据特征,并制作数据集,数据集中数据格式为:气体标签;浓度值;特征:观测值;并对观测值进行预处理;得到数据样本集;

[0010] 构建改进后的FNN模型,基于样本集对模型进行训练,得到训练好的改进后的FNN模型;其中,模型改进包括:每层采用Leaky Rectified Linear Unit激活函数,加入批量归一化在每一层的输出上进行规范化,归一化后的输出进行线性变换,对梯度下降或爆炸进行优化;每层都设置Dropout层,用于随机丢弃部分神经元,防止过拟合;采用Adam优化器进行参数优化,并采用交叉熵损失函数对模型进行训练评估。

[0011] 基于训练好的改进后的FNN模型对测试数据进行分类识别,得到分类结果。

[0012] 进一步的,数据集中,每个气体标签对应多个浓度值和多个特征,每个特征对应多个观测值,对观测值进行预处理包括:采用均值填充策略填充缺失数据,并对填充后的每个特征对应的多个观测值进行标准化,标准化后数据集为样本集。

[0013] 进一步的,改进后的FNN模型中,Leaky Rectified Linear Unit激活函数表达式为:

$$[0014] \quad f(x) = \max(\alpha x, x)$$

[0015] 其中, $f(x)$ 表示激活函数的输出, $x$ 表示激活函数的输入值, $\alpha x$ 表示激活函数的输出值;

[0016] 批量归一化公式为:

$$[0017] \quad \hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

[0018] 其中, $\hat{x}$ 表示标准化后的中间值, $x$ 表示, $\mu_B$ 是当前批次数据上所有输入的均值, $\sigma_B^2$ 是当前批次数据上所有输入的方差, $\epsilon$ 是一个极小的正数;

[0019] 线性变换公式为:

$$[0020] \quad y = \gamma \hat{x} + \beta$$

[0021] 其中, $y$ 表示批量归一化后的最终输出值, $\gamma$ 和 $\beta$ 分别是学习到的可调缩放和平移参数。

[0022] 进一步的,改进后的FNN模型中,Dropout层操作为:

$$[0023] \quad \tilde{y} = y \cdot r$$

[0024] 其中, $\tilde{x}$ 表示Dropout层处理后的输出数据, $x$ 表示Dropout层输入数据, $r$ 是一个随机生成的二进制掩码。

[0025] 进一步的,Adam优化器的更新规则为:

$$[0026] \quad m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

$$[0027] \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

$$[0028] \quad \hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

$$[0029] \quad \theta_t = \theta_{t-1} - \frac{\alpha \hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

[0030] 梯度代表函数在某个点的方向导数向量,它指向函数值增加最快的方向,并且其大小表示函数变化的剧烈程度。在此项目中,表示函数在每个维度上的变化率。其中, $m_t$ 是当前动量(模拟物理中的速度),在梯度更新时给梯度增加一个惯性,使得优化路径更加平滑,不会过度摆动,通过指数移动平均累积梯度, $m_{t-1}$ 是前一步的动量, $\beta_1$ 是一阶矩的指数衰

减率,  $g_t$  是当前时间步  $t$  的梯度, 即损失函数对参数  $\theta_{t-1}$  的梯度;  $v_t$  是当前平方梯度的指数移动平均,  $v_{t-1}$  是前一步的平方梯度的指数移动平均,  $\beta_2$  是二阶矩的指数衰减率,  $\hat{m}_t$  是偏差修正后的动量,  $\hat{v}_t$  是偏差修正后的平方梯度,  $\beta_1^t$  是表示  $\beta_1$  在第  $t$  步的幂次,  $\beta_2^t$  是表示  $\beta_2$  在第  $t$  步的幂次,  $\theta_t$  是更新后的模型参数,  $\theta_{t-1}$  是前一步的参数,  $\alpha$  是学习率,  $\epsilon$  为数值稳定性常数;

[0031] 交叉熵损失函数为:

$$[0032] \quad L = - \sum_{i=1}^c y_i \log(p_i)$$

[0033] 其中,  $L$  是损失值,  $C$  是类别数,  $y_i$  是实际标签,  $p_i$  是模型预测的类别  $i$  的概率,  $\log(p_i)$  表示对预测概率  $p_i$  取自然对数。

[0034] 本发明还提供了一种基于改进FNN的智能家居空气检测识别系统, 包括:

[0035] 数据采集模块, 用于采集室内空气中污染物数据, 以及室内气压和温度数据;

[0036] 数据处理模块, 用于提取数据特征, 并制作数据集, 数据集中数据格式为: 气体标签; 浓度值; 特征: 观测值; 并对观测值进行预处理; 得到数据样本集;

[0037] 模型构建及训练模块, 用于构建改进后的FNN模型, 基于样本集对模型进行训练, 得到训练好的改进后的FNN模型; 其中, 模型改进包括: 每层采用Leaky Rectified Linear Unit激活函数, 加入批量归一化在每一层的输出上进行规范化, 归一化后的输出进行线性变换, 对梯度下降或爆炸进行优化; 每层都设置Dropout层, 用于随机丢弃部分神经元, 防止过拟合; 采用Adam优化器进行参数优化, 并采用交叉熵损失函数对模型进行训练评估。

[0038] 分类识别模块, 用于基于训练好的改进后的FNN模型对测试数据进行分类识别, 得到分类结果。

[0039] 可选的, 数据采集模块, 包括STM32微控制器、空气检测模块、BMP280气压计模块、通信模块和物联网平台, 空气检测模块用于检测室内空气中污染物数据, BMP280气压计模块用于采集室内气压和温度数据, 污染物数据、气压和温度数据通过通信模块传输至STM32微控制器, STM32微控制器对数据进行处理后通过通信模块上传至物联网平台, 物联网平台用于数据的显示和存储, 并实现分类识别结果的保存和显示。

[0040] 可选的, STM32微控制器将实时检测数据通过OLED屏幕显示;

[0041] 空气检测模块包括TGS2600、TGS2602、TGS2610和TGS2620四种不同空气检测传感器, 通过加热电路和信号处理电路, 将气体浓度转换为可测量的电压信号, 再通过ADC转换为数字信号供STM32处理;

[0042] 通信模块为ESP8266-12F WIFI模块, 内置微控制器和TCP/IP协议栈, 能够实现无线数据传输。

[0043] 本发明还提供了一种电子设备, 所述设备包括:

[0044] 存储有可执行程序代码的存储器;

[0045] 与所述存储器耦合的处理器;

[0046] 所述处理器调用所述存储器中存储的所述可执行程序代码, 执行所述的基于改进FNN的智能家居空气检测识别方法的步骤。

[0047] 本发明还提供了一种计算机可读存储介质, 所述计算机可读存储介质存储有计算机指令, 所述计算机指令被调用时, 用于执行所述的基于改进FNN的智能家居空气检测识别

方法的步骤。

[0048] 有益效果:与现有技术相比,本发明的显著技术效果为:(1)改进的前反馈神经网络(FNN)算法及其在嵌入式环境中的优化应用;通过剪枝、量化等技术,将FNN模型体积从10MB压缩至约200KB,打造了一套STM32的Flash/RAM资源,同时保持>95%的准确率;优化后的推理速度达到毫秒级(单次检测<50ms),满足智能家居的实时响应需求;此外,模型支持在线增量学习(如通过阿里云更新权重),可根据不同的家庭环境(如新装修房屋、宠物家庭)进行自适应优化;(2)在系统架构方面,充分利用STM32的低功耗特性,并与阿里云平台无缝对接,支持远程监控(如手机App、智能音箱),覆盖智能家居生态系统。当检测到超标时,系统可自动联动空气净化器、新风系统等设备,实现主动防护。长期云端数据存储与分析可生成空气质量报告,为用户提供净化的通风、净化策略建议;同时,STM32本地运行FNN模型,减少对云端计算的依赖,降低通信成本与延迟,进一步提升系统的稳定性和响应速度;(3)另外,STM32的低功耗设计高效延长设备续航,适用于电池供电场景。用户可通过阿里云自定义污染阈值(如孕妇模式下甲醛阈值设置 $0.05\text{mg}/\text{m}^3$ 解决),满足个性化需求;这就涉及到传统方案(如纯云端分析导致的高延迟、未优化的卷积神经网络模型资源占用大),本发明基于嵌入式AI+物联网的融合设计,实现了智能家居检测领域的高成本、低实时性、弱泛化性等痛点。

## 附图说明

- [0049] 图1为本发明方法流程图;
- [0050] 图2为本发明硬件电路原理图;
- [0051] 图3为基于STM32的硬件平台、阿里云平台和改进FNN网络运行结构示意图;
- [0052] 图4为传统FNN模型结构示意图;
- [0053] 图5为改进FNN模型结构示意图;
- [0054] 图6为本发明方法详细流程图;
- [0055] 图7为仿真效果图,其中(a)为传统FNN模型仿真效果图,(b)为改进FNN模型仿真效果图;
- [0056] 图8为改进FNN模型检测准确率和损失曲线示意图,其中(a)为模型准确率曲线示意图,(b)为模型损失曲线示意图。

## 具体实施方式

- [0057] 下面结合附图和具体实施例对本发明进行详细说明。
- [0058] 如图1所示,为了达到上述发明目的,本发明所述基于改进FNN的智能家居空气检测识别方法,具体流程如下:
- [0059] S1、采集室内空气中污染物数据,以及室内气压和温度数据;具体如下:
- [0060] 如图2所示,采用空气检测系统检测室内空气中的污染物,如甲醛、苯、氨气等有害气体。本实施例中空气检测系统包括TGS2600、TGS2602、TGS2610和TGS2620四种不同的空气检测传感器,并将TGS2600、TGS2602、TGS2610和TGS2620传感器连接到STM32最小系统板的ADC引脚,进行模拟信号到数字信号的转换。
- [0061] 采用气压温度检测模块检测室内气压和温度,本实施例中气压温度检测模块采用



BMP280传感器,检测的室内气压和温度这些数据有助于提高空气检测的准确性。通过I<sup>2</sup>C接口将BMP280传感器连接到STM32微控制器,读取气压和温度数据。BMP280传感器是一种高精度的数字气压计和温度计,内置ADC和信号处理电路,能够提供准确的气压和温度数据。通过I<sup>2</sup>C接口与STM32微控制器通信,简化了电路设计。

[0062] STM32硬件平台的核心芯片设置在STM32最小系统板上,STM32最小系统板包括STM32F103ZET6、晶振电路、复位电路、电源电路等基本组件。STM32最小系统板还连接有OLED显示模块,用于实时显示检测数据。OLED显示模块采用0.96寸OLED(有机发光二极管)屏幕。STM32最小系统板和OLED显示模块结构示意图如图2所示。

[0063] 使用STM32F103ZET6作为核心处理单元,负责数据采集、处理和传输。配置STM32的外设接口,包括ADC(模数转换器)、I<sup>2</sup>C(串行通信总线协议)和USART(异步串行收发模块)。使用OLED屏幕显示基础数据。所述STM32最小系统板采用USART串口进行信息传输和控制包括:

[0064] (1) 启动搭载STM32F103ZET6的STM32最小系统板,并进行TGS2600、TGS2602、TGS2610和TGS2620的AD、OLED、BMP280的MyI<sup>2</sup>C和ESP8266-12F的串口模块进行初始化。

[0065] (2) 通过串口,完成对WIFI模块(ESP8266)的相关阿里云配置,连接网络和阿里云的物联网平台;

[0066] (3) 对OLED显示屏操作,显示静态字符;

[0067] (4) 循环执行STM32对温度、气压和TGS2600、TGS2602、TGS2610和TGS2620的特征值数据的采样,通过ESP8266上传阿里云平台;基于STM32的硬件平台、阿里云平台和改进FNN算法的运行结构示意图如图3所示。

[0068] STM32微控制器与多个传感器以及阿里云平台之间的通信均采用ESP8266-12FWIFI模块;ESP8266-12F是一款低成本的WIFI模块,内置微控制器和TCP/IP协议栈,能够实现无线数据传输。通过USART接口与STM32通信,实现数据的无线传输。使用ESP8266-12F模块实现无线网络连接,将采集的数据传输到阿里云平台。配置ESP8266的固件,使其能够与STM32通过USART进行通信,并实现MQTT协议栈。

[0069] 阿里云平台提供物联网通信功能,实现STM32系统与云端的数据交互,包括数据上传和识别结果的返回,如图3所示。在阿里云平台上收集并存储硬件设备上传的数据,以用于训练和学习空气污染物的特征。STM负责采集环境数据,并对其进行处理后上传至阿里云,随后通过改进的FNN算法进行进一步分析与识别。传感器测得的信号以电阻时间序列的形式读取,每次测量形成一个多通道时间序列。在本方案中,每个测量周期的传感器数据包含16个通道,并从中提取8个特征,其中包括2个稳态特征和6个动态特征。最终,每次测量得到一个128维特征向量(16个传感器×8个特征)。稳态特征:包括最大电阻变化和归一化的稳态电阻变化,用于描述传感器的稳定响应。动态特征:采用指数移动平均滤波计算传感器的瞬态响应,共提取6个特征,以反映传感器对污染物的变化趋势。STM32在完成数据采集和特征提取后,将8维特征数据上传至阿里云平台,随后通过改进FNN算法进行污染物识别和分析,提高分类准确性。

[0070] S2、提取数据特征,并制作数据集,数据集中数据格式为:气体标签;浓度值;特征:观测值;并对观测值进行预处理;得到数据样本集;

[0071] 从阿里云爬取数据,获得数据后通过改进FNN算法进行进一步的分析和识别。整个

项目使用面向对象编程方式封装,定义了一个GasSensorModel这个类,它包括数据读取、预处理,模型训练,项目,结果可视化这几个函数。首先创建这个类,进行参数的初始化,包括初始化文件路径,气体名称,气体名称到数值的映射(编码),训练集、验证集、测试集及其对应标签,存储训练历史,改进后的FNN模型等。

[0072] 批量加载多个.dat文件并合并数据,对于每个.dat文件是进行数据处理,逐行读取.dat文件中的数据,解析数据将其转化成字典格式,转换成Pandas DataFrame,返回数据。为数据添加Batch ID,气体类别和浓度,处理特征数据,将数据按照气体标签排序并重新索引,对标签进行编码,即映射气体标签为数值,本项目将乙醇,乙烯,氨,乙醛,丙烯,甲苯分别映射为1,2,3,4,5,6。使得每个数据点的格式为:气体标签;浓度值特征1:观测值1特征2:观测值2...,即格式为特征X:观测值x,其中气体标签是一个数值,表示不同类型的气体。使用sklearn.utils.shuffle进行数据洗牌,避免模型学习到数据分布的固定模式。

[0073] 将上述得到的数据保存到CSV文件中,方便数据复用,避免重复读取.dat文件,可以在其他环境中加载这个CSV文件,进行数据分析或训练不同的模型。

[0074] 每个气体标签对应多个浓度值和多个特征,每个特征对应多个观测值,对观测值进行预处理包括:采用均值填充策略填充缺失的观测值数据,并对填充后的每个特征对应的多个观测值进行标准化,标准化后数据集为样本集。具体如下:

[0075] 对观测值进行缺失值处理,采用均值填充策略填充缺失数据,对于每个包含缺失值的特征(即特征1、特征2...),计算该特征下的所有观测值数据的均值,然后将所有缺失的值用均值填充,n表示整个数据集中的特征X中的总观测值数量,均值填充的公式为:

$$[0076] \quad \mu_x = \frac{1}{n} \sum_{i=1}^n x_i \quad (1)$$

[0077] 其中, $x_i$ 是特征X中的第i个观测值, $\mu_x$ 表示特征X中n个观测值的均值, $\sum_{i=1}^n x_i$ 表示对从i=1到i=n的所有 $x_i$ 进行求和并对该特征X下所有观测值进行标准化处理,通过减去均值并除以标准差来将数据转换为标准正态分布。

[0078] 设某特征X中的每一个观测值为 $x_1, x_2, \dots, x_i$ ,特征X中的所有观测值的均值为 $\mu_g$ ,特征X中的所有观测值的标准差为 $\sigma_x$ ,那么第i个观测值 $x_i$ 标准化后的值为 $z_i$ :

$$[0079] \quad z_i = \frac{x_i - \mu_x}{\sigma_x} \quad (2)$$

[0080] 其中,由公式(1)可知 $\mu_g$ 为特征X的所有观测值的均值, $\sigma_x = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)^2}$ 是特征X的所有观测值的标准差,确保特征X中的所有数据在同一尺度下进行训练。

[0081] 标准化后数据集为样本集,将样本集划分为训练集、验证集和测试集,用于后续模型的训练和测试。本实施例中,将样本集中随机抽取80%的数据用于训练和验证,其中20%的数据用于测试。

[0082] S3、构建改进后的FNN模型,基于样本集对模型进行训练,得到训练好的改进后的FNN模型;如图4所示为传统FNN模型结构示意图,如图5所示,改进后的FNN模型包括输入层、四个隐藏层和输出层,每个隐藏层中均包括全连接层(对输入数据执行线性变换)、Leaky Rectified Linear Unit(Leaky ReLU)激活函数、批量归一化(Batch Normalization)处理和丢弃(Dropout)层;模型改进包括:每个隐藏层采用Leaky ReLU激活函数,加入Batch

Normalization处理在每一隐藏层的输出上进行规范化,对Batch Normalization后的输出进行线性变换,对梯度下降或爆炸进行优化;每个隐藏层都设置Dropout层,用于随机丢弃部分神经元,防止过拟合;采用Adaptive Moment Estimation(Adam)优化器进行参数优化,并采用交叉熵损失函数对模型进行训练评估。

[0083] 本发明使用神经网络架构进行分类任务,改进后的FNN模型包括多个隐藏层。传统前反馈神经网络(FNN)只包括多个全连接层和激活函数,如图4所示,可能会遇到梯度消失/爆炸、过拟合和训练速度慢等问题。针对上述问题,本发明提出改进FNN模型来解决上述问题,具体改进点为:

[0084] (1) 每个隐藏层采用Leaky ReLU激活函数替换了ReLU激活函数,减少了神经元“死亡问题”,提高临界传播能力,用于优化梯度下降或爆炸;

[0085] 用 $f(c)$ 表示激活函数的输出, $c$ 表示激活函数的输入值(即标准化后并且进行神经元的加权和加上偏置项后的值),则:

$$[0086] \quad f(c) = \max(\alpha c, c) \quad (3)$$

[0087] 当 $c$ 大于零时,激活函数的输出值与输入值相同。当 $c$ 小于等于零时,输出为 $\alpha c$ ,防止梯度消失。其中, $\alpha$ 是一个小的常数,通常取值为0.01或0.1。 $\max$ 表示选择两个值中的较大者。这样在负值区间也能有非零的输出,避免了模型训练过程中的“梯度消失”问题。

[0088] 此外,Batch Normalization在每一层隐藏层激活函数的输出 $f(c)$ 上进行规范化,使得每一层的输出在每一维上的均值为0,方差为1。对于每个小批量的数据(在训练过程中每次迭代时从整个数据集中抽取的一小部分样本),用 $\hat{x}$ 表示标准化后的Batch Normalization通过以下公式进行变换:

$$[0089] \quad \hat{c} = \frac{f(c) - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} \quad (4)$$

[0090] 其中: $\mu_B$ 是当前批次数据上某一隐藏层的每个神经元对应的所有样本的激活值的均值, $\sigma_B^2$ 是当前批次数据上所有输入的方差, $\epsilon$ 是一个极小的正数(例如 $10^{-k}$ 或 $10^{-l}$ ),用于避免除零错误。

[0091] 归一化后的输出再进行一个线性变换,用 $y$ 表示Batch Normalization后的最终输出值:

$$[0092] \quad y = \gamma \hat{c} + \beta \quad (5)$$

[0093] 其中, $\gamma$ 和 $\beta$ 分别是学习到的可调缩放和平移参数,用于恢复网络的表示能力。通过这两个参数,神经网络可根据需要调整数据的尺度和偏移量。这样缓解了梯度消失或梯度爆炸的问题,使得网络能够更快地收敛,通过平衡各层输入的分布,提高了模型的鲁棒性。

[0094] (2) 采用学习率衰减(ReduceLROnPlateau)机制优化过拟合

[0095] 本发明加入ReduceLROnPlateau机制,在验证损失停止下降时,自动减少学习率,提高收敛效果。设定一个监视指标,如果其连续多轮未减少,则当前学习率乘以一个因子进行衰减。本发明设置提前终止机制。在训练过程中,如果验证集上的损失值在连续多个周期内没有明显下降,则停止训练。通常在损失没有改善时停止训练,以避免过拟合。

[0096] Dropout防止过拟合。在训练时,随机丢弃神经网络中的某些神经元,使其在当前

训练步骤中不参与计算。对于改进FNN模型每一隐藏层,在每个训练步骤中,Dropout层将随机丢弃一部分神经元,即设定每个神经元的保留概率为 $p$ ,其他神经元的值为零。在训练过程中,对于Batch Normalization后的最终输出值 $y$ ,用 $\tilde{y}$ 表示经过Dropout处理后的输出数据,Dropout操作为:

$$[0097] \quad \tilde{y} = y \cdot r \quad (6)$$

[0098] 其中, $r$ 是一个随机生成的二进制掩码,是一个由0和1组成的随机向量。每个元素的值为1或0,表示神经元是否“保留”在当前训练步骤中。 $r$ 的值是根据设定的 $p$ 随机生成的。且 $\mathbb{P}(r = 1) = p$ ,  $\mathbb{P}(r = 0) = 1 - p$ 。其中 $\mathbb{P}$ 表示求概率。这样避免了模型的过拟合,通过随机丢弃神经元,使模型更具泛化能力。提高了模型的鲁棒性,减少了过于依赖某些特定神经元的问题。

[0099] (3) 采用Adam优化器优化训练速度

[0100] 梯度代表函数在某个点的方向导数向量,它指向函数值增加最快的方向,并且其大小表示函数变化的剧烈程度。在此项目中,表示函数在每个维度上的变化率。训练时使用Adam优化器对每个改进FNN模型参数的梯度进行偏置校正,维护一阶矩(梯度的均值)和二阶矩(梯度的平方均值)。Adam优化器的更新规则如下:

$$[0101] \quad m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (7)$$

$$[0102] \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (8)$$

$$[0103] \quad \hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (9)$$

$$[0104] \quad \theta_t = \theta_{t-1} - \frac{s \hat{m}_t}{\sqrt{\hat{v}_t} + \varphi} \quad (10)$$

[0105] 其中, $m_t$ 是当前动量(模拟物理中的速度),在梯度更新时给梯度增加一个惯性,使得优化路径更加平滑,不会过度摆动,通过指数移动平均累积梯度, $m_{t-1}$ 是前一步的动量; $\beta_1$ 是一阶矩(动量)的指数衰减率,控制历史梯度信息的保留比例(通常取0.9); $g_t$ 是当前时间步 $t$ 的梯度,即损失函数对参数 $\theta_{t-1}$ 的梯度; $v_t$ 是当前平方梯度的指数移动平均,用于自适应调整学习率, $v_{t-1}$ 是前一步的平方梯度的指数移动平均; $\beta_2$ 是二阶矩(平方梯度)的指数衰减率,控制历史梯度平方的保留比例(通常取0.999); $\hat{m}_t$ 是偏差修正后的动量; $\hat{v}_t$ 是偏差修正后的平方梯度; $\theta_t$ 是更新后的模型参数(在这里表示神经网络的所有权重和偏置以及批量归一化层的可学习参数 $\gamma$ 和 $\beta$ ), $\theta_{t-1}$ 是前一步的模型参数向量; $s$ 是学习率,决定参数更新的幅度; $\varphi$ 为数值稳定性常数,防止分母为零(通常取 $1e-8$ )。

[0106] Adam优化器能够自适应调整学习率,提高了训练速度,结合了动量法和Root Mean Square Propagation的优点,能有效处理稀疏梯度问题。运用交叉熵损失函数,对于多类分类问题,交叉熵损失函数被定义为:

$$[0107] \quad L = -\sum_{u=1}^k y_u \log(p_u) \quad (11)$$

[0108] 其中: $L$ 是损失值。 $k$ 是类别数。 $y_i$ 是实际标签,通常是一个独热编码。 $p_u$ 是模型预测

的类别 $u$ 概率,通过Softmax函数输出得到, $p_u = \frac{e^{f_u}}{\sum_{j=1}^k e^{f_j}}$ , $f_s$ 是改进FNN模型输出层的线性输出。 $\log(p_i)$ 表示对预测概率 $p_i$ 取自然对数(底数为 $e$ )。此算法能有效地衡量模型输出概率与

实际标签之间的差距。比均方误差更加适用于分类问题,能够更好地指导模型学习。此外,本发明设置提前终止机制。在训练过程中,如果验证集上的损失值在连续多个周期内没有明显下降,则停止训练。通常在损失没有改善时停止训练,以避免过拟合。图4和图5分别为FNN和改进FNN的可视化模型结构。图6为气体检测识别方法详细流程图。

[0109] 对模型进行训练,实现动态学习率调整,进行批量训练,并且使用验证集进行评估,计算预测值,计算混淆矩阵和准确率,通过可视化的方式绘制准确率曲线,损失曲线和混淆矩阵进行模型评估和改进。其中混淆矩阵是分类问题中常用的评估指标之一,它用于衡量模型在测试集上的表现。混淆矩阵能直观地展示模型的正确分类情况和错误分类情况,从而深入理解模型的优缺点。对于多分类问题(比如本项目的气体传感器分类任务),混淆矩阵是一个 $k \times k$ 的表格,其中 $k$ 是类别数,矩阵的对角线表示正确分类的数量,非对角线的元素表示分类错误的数量。

[0110] S4、基于训练好的改进后的FNN模型对测试数据进行分类识别,得到分类结果。

[0111] 此外,为了说明本发明所提改进FNN的优越性,本发明在公开数据集上验证了FNN和改进FNN模型的效果(计算准确率、混淆矩阵),具体如图7中(a)和(b)所示,两幅图的对角线左上角表示正确分类为乙醇的数量,以此类推。在对角线上的数量越多模型越好预测概率越准。图8中(a)和(b)分别表示改进FNN模型训练过程中的准确率和损失曲线,其中,两条曲线越趋向贴合,说明该训练的模型越好,识别准确率越高。

[0112] 本发明通过软硬件平台和深度学习算法的相互协助(STM32硬件平台、阿里云物联网平台和改进FNN算法),开发出一种新型空气检测方式,能够有效提高检测精度和增强数据可视化效果,为后续智能环境控制系统的搭建提供可靠的技术支撑。

[0113] 一种基于改进FNN的智能家居空气检测识别系统,包括:

[0114] 数据采集模块,用于采集室内空气中污染物数据,以及室内气压和温度数据;数据采集模块,包括STM32微控制器、空气检测模块、BMP280气压计模块、通信模块和物联网平台,空气检测模块用于检测室内空气中污染物数据,BMP280气压计模块用于采集室内气压和温度数据,污染物数据、气压和温度数据通过通信模块传输至STM32微控制器,STM32微控制器对数据进行处理后通过通信模块上传至物联网平台,物联网平台用于数据的显示和存储,并实现分类识别结果的保存和显示。

[0115] STM32微控制器将实时检测数据通过OLED屏幕显示;

[0116] 空气检测模块包括TGS2600、TGS2602、TGS2610和TGS2620四种不同空气检测传感器,通过加热电路和信号处理电路,将气体浓度转换为可测量的电压信号,再通过ADC转换为数字信号供STM32处理;

[0117] 通信模块为ESP8266-12F WIFI模块,内置微控制器和TCP/IP协议栈,能够实现无线数据传输。

[0118] 数据采集模块的具体硬件结构如上述步骤S1中所述。

[0119] 数据处理模块,用于提取数据特征,并制作数据集,数据集中数据格式为:气体标签;浓度值;特征:观测值;并对观测值进行预处理;得到数据样本集;

[0120] 模型构建及训练模块,用于构建改进后的FNN模型,基于样本集对模型进行训练,得到训练好的改进后的FNN模型;其中,模型改进包括:每层采用LeakyReLU激活函数,加入批量归一化在每一层的输出上进行规范化,归一化后的输出进行线性变换,对梯度下降或

爆炸进行优化;每层都设置Dropout层,用于随机丢弃部分神经元,防止过拟合;采用Adam优化器进行参数优化,并采用交叉熵损失函数对模型进行训练评估。

[0121] 分类识别模块,用于基于训练好的改进后的FNN模型对测试数据进行分类识别,得到分类结果。

[0122] 本发明所述一种电子设备,包括:

[0123] 存储有可执行程序代码的存储器;

[0124] 与所述存储器耦合的处理器;

[0125] 所述处理器调用所述存储器中存储的所述可执行程序代码,执行所述的基于改进FNN的智能家居空气检测识别方法的步骤。

[0126] 本发明所述一种计算机可读存储介质,所述计算机可读存储介质存储有计算机指令,所述计算机指令被调用时,用于执行所述的基于改进FNN的智能家居空气检测识别方法的步骤。




图1




图2






图3




图4




图5




图6




图7




图8